
ANALIZA I EKSPLORACJA DANYCH O ARTYSTACH Z PLATFORMY SPOTIFY I YOUTUBE

Autorzy

MATEUSZ GWIZDAK 252945

FILIP HELLWIG 252904

PATRYK GAJDA 252915

Prowadzący

dr inż. Agata Migalska

Kurs

Metody Analizy i Eksploracji Danych

Spis treści

1	Propozycja projektu	2
1.1	Dane i źródła	2
1.2	Opis problemu	2
2	Eksploracyjna analiza danych	3
2.1	Informacje o pochodzeniu danych	3
2.2	Brakujące dane	3
2.3	Opis zmiennych	3
2.4	Przygotowanie danych	5
2.4.1	Przygotowanie danych o gatunkach	5
2.5	Analiza rozkładów zmiennych	6
2.6	Analiza zależności między zmiennymi	13
2.6.1	Korelacja poszczególnych zmiennych	14
2.6.2	Wyświetlenia od Gatunku	14
2.6.3	Wyświetlenia od Taneczności	15
2.6.4	Wyświetlenia od Tonacji	17
2.6.5	Wyświetlenia od Pozytywności	18
2.6.6	Średnia taneczność w popularnych gatunkach	20
2.6.7	Średnia ilość słów w popularnych gatunkach	21
2.6.8	Średnia długość utworu w popularnych gatunkach	22
2.6.9	Średnie tempo w popularnych gatunkach	23
3	Ekstrakcja wiedzy z danych	23
3.1	Wstęp	23
3.2	Wyniki klastrowania	24
3.3	Wyniki klasyfikacji	26
3.4	Zalety i wady zaproponowanych rozwiązań	27
3.4.1	Klastrowanie	27
3.4.2	Klasyfikacja	27
4	Kierunki dalszego rozwoju	28
5	Podsumowanie	28

1 Propozycja projektu

1.1 Dane i źródła

Zbiór danych jest listą utworów różnych artystów z całego świata wraz ze statystykami z platformy do słuchania muzyki Spotify oraz z platformy do odtwarzania wideo Youtube.

Część informacji jakie można uzyskać to: utwór, artysta, album, typ albumu, głośność, ilość wyświetleń/odsluchań.

Wykorzystywane dane pochodzą z portalu kaggle.com.

1.2 Opis problemu

Projekt dotyczyć będzie przetwarzania i analizy danych koncentrując się na badaniu popularnych utworów na platformach Spotify i YouTube. Głównym celem jest zgromadzenie, uporządkowanie oraz analiza danych dotyczących tych utworów, w celu wyodrębnienia szczegółowych cech charakteryzujących je oraz zidentyfikowania ewentualnych zależności między nimi a ich poziomem popularności.

W pierwszym etapie projektu, dane z obu platform zostaną zebrane i poddane odpowiedniemu przetwarzaniu, co pozwoli na stworzenie spójnego zbioru informacji. Następnie, baza danych zostanie poddana eksploracyjnej analizie, w trakcie której zostaną zidentyfikowane rozkład zmiennych i korelacje między nimi. Ta analiza posłuży również jako przygotowanie danych o utworach pod dalsze obserwacje oraz wyciągnięcie interesujących wniosków.

Kolejnym krokiem jest dokonanie klasteryzacji danych na podstawie gatunków. Ta technika eksploracji pozwoli na zrozumienie, czy cechy które posiada utwór pozwalają na dopasowanie go z innymi piosenkami stworzonymi w tym samym gatunku.

Wartościowe wnioski z tego projektu mogą posłużyć jako cenne wskazówki dla twórców muzyki, producentów i platform streamingowych, pozwalając im lepiej zrozumieć mechanizmy decydujące o popularności utworów oraz dostosować swoje strategie do oczekiwań odbiorców na obu platformach.

2 Eksploracyjna analiza danych

2.1 Informacje o pochodzeniu danych

Wykorzystane dane pochodzą z platformy kaggle.com. Zostały zebrane z platformy Spotify oraz Youtube. Na dane wpływa dzień w którym zostały zebrane, gdyż ilość wyświetleń i polubień jest zmienna w czasie. Informacje o gatunkach zostały przygotowane w ramach projektu. Nazwy gatunków zostały zebrane przy pomocy API z platformy Last.fm (2.4).

2.2 Brakujące dane

Większość brakujących danych wynika z braku części danych ze Spotify. Może to wynikać z faktu że zdecydowanie więcej muzyki jest na Youtube i część muzyki z wykorzystywanych danych nie znajduje się na Spotify.

2.3 Opis zmiennych

- Poziom taneczności (Danceability) - zmienna numeryczna, liczba rzeczywista, pomiędzy 0 i 1, gdzie 1 to poziom maksymalny; opisuje, jak odpowiedni jest to utwór do tańca na podstawie: tempa, stabilności rytmu, siły uderzeń oraz rytmiczności,
- Poziom energii (Energy) - zmienna numeryczna, liczba rzeczywista, pomiędzy 0 i 1, gdzie 1 to poziom maksymalny; opisuje miarę intensywności i żywiołowości,
- Tonacja (Key) - liczba całkowita, od -1 do 11, gdzie -1 oznacza brak danych, 0 oznacza gamę C, 1 oznacza gamę Cis, itd.; tonacja w jakiej napisany jest utwór,
- Głośność (Loudness) - zmienna numeryczna, liczba rzeczywista, pomiędzy 0 i 1, gdzie 1 to poziom maksymalny; ogólna głośność ścieżki w decybelach,
- Cecha mówności (Speechiness) - zmienna numeryczna, liczba rzeczywista, pomiędzy 0 i 1, gdzie 1 to poziom maksymalny; im bardziej charakteryzuje się nagranie mównymi cechami (np. programem rozmów, audiobookiem, poezją), tym wartość większa, wartości w środku zakresu opisują utwór zawierający i mowę, i muzykę (np. rap). Wartości małe reprezentują muzykę i inne utwory, które nie wykazują cech mównych.

- Stopień akustyczności (Acousticness) - zmienna numeryczna, liczba rzeczywista, pomiędzy 0 i 1, gdzie 1 to poziom maksymalny; przewiduje czy utwór jest akustyczny,
- Stopień instrumentalności (Instrumentalness) - zmienna numeryczna, liczba rzeczywista, pomiędzy 0 i 1, gdzie 1 to poziom maksymalny; określa prawdopodobieństwo czy utwór jest instrumentalny (nie zawiera słów),
- Szansa że piosenka jest nagrana na żywo (Liveness) - zmienna numeryczna, liczba rzeczywista, pomiędzy 0 i 1, gdzie 1 to poziom maksymalny; przewiduje czy utwór jest nagrany na żywo (na podstawie obecności publiczności w nagraniu),
- Pozytywność (Valence) - zmienna numeryczna, liczba rzeczywista, pomiędzy 0 i 1, gdzie 1 to poziom maksymalny; opisuje muzyczną pozytywność przekazywaną przez utwór,
- Tempo (Tempo) - zmienna numeryczna, liczba naturalna większa od 0; ogólne szacowane tempo utworu w uderzeniach na minutę,
- Czas trwania piosenki (Duration) - zmienna numeryczna, czas w milisekundach,
- Wyświetlenia (Views) - zmienna numeryczna, liczba naturalna większa lub równa 0; wyświetlenia na platformie Youtube,
- Polubienia (Likes) - zmienna numeryczna, liczba naturalna większa lub równa 0; polubienia na platformie Youtube,
- Streamy (Stream) - zmienna numeryczna, liczba naturalna większa lub równa 0; odtworzenia na platformie Spotify,
- Gatunek (Genre) - zmienna kategoryczna, nominalna; nazwa gatunku, który reprezentuje dany wykonawca.

2.4 Przygotowanie danych

2.4.1 Przygotowanie danych o gatunkach

Cecha 'Genre' oznaczająca główny gatunek, do którego przyporządkowany jest dany twórca muzyczny, nie była oryginalnie zawarta w wykorzystanym zbiorze danych. Jest to jednak cecha, dzięki której dochodzą dodatkowe możliwości, aby przeprowadzić istotną analizę, eksplorację danych oraz dać perspektywę dla zadania predykcji, czy klasteryzacji. Gatunki muzyczne zostały pobrane i wczytane do bazy danych poprzez API udostępniane przez portal [Last.fm](https://last.fm) przy pomocy biblioteki *requests*.


Fragment kodu:

```
1 def get_music_genre(artist):
2     api_key = ''
3     base_url = 'http://ws.audioscrobbler.com/2.0/'
4     params = {
5         'method': 'artist.getinfo',
6         'artist': artist,
7         'api_key': api_key,
8         'format': 'json'
9     }
10
11     response = get_with_retry(base_url, params=params, timeout=600,
12                               max_retries= 5)
13     data = response.json()
14     print(artist)
15     if 'error' in data:
16         return 'Błąd'
17     elif 'artist' in data and 'tags' in data['artist'] and 'tag' in data['artist']['tags']:
18         tags = data['artist']['tags']['tag']
19         if tags:
20             return tags[0]['name']
21         else:
22             return 'Brak informacji'
23     else:
24         return 'Brak informacji'
25
26 unique = df['Artist'].unique()
27 unique = pd.DataFrame({"Artist":unique})
28
29 unique["Genre"] = None
30 unique["Genre"] = unique["Artist"].apply(get_music_genre)
31
32 df = df.merge(unique, on='Artist', how='left')
```

2.5 Analiza rozkładów zmiennych

Rozkład zmiennych został przedstawiony w postaci histogramów oraz dodatkowo funkcji gęstości prawdopodobieństwa wygenerowanej metodą jądrową. Wiersze, w których wartość danej kolumny wynosiła *NULL* nie były brane pod uwagę podczas generowania wykresów w tym, jak i kolejnych sekcjach.


- Danceability - zakres $<0,1>$



Rysunek 1: Rozkład zmiennej 'Danceability'

Jak widzimy, największa ilość piosenek zawartych w zbiorze posiada wartość tej zmiennej w zakresach od ok. 0.5 do ok. 0.8. Występuje bardzo niewielka ilość dla wartości bliskich granicznym zakresu. Większość utworów jest więc w pewnym stopniu rytmiczne, nadające się do tańca.


- Energy - zakres $<0,1>$



Rysunek 2: Rozkład zmiennej 'Energy'

Możemy zauważyć, że w zbiorze znalazły się raczej energiczne utwory, choć nie zabrakło również tych mało energicznych. Wykres odzwierciedla najpopularniejsze gatunki zawarte w zbiorze i ich charakterystykę.

- Key - wartości całkowite <0,11>




Rysunek 3: Rozkład zmiennej 'Key'

W zbiorze znalazły się utwory we wszystkich możliwych notacjach. Naj-

mniej popularna jest notacja o nr 3, co odpowiada notacji $D_{\sharp}/E_{\flat}$.


- Loudness zakres $<-60 \text{ dB}, 0 \text{ dB}>$



Rysunek 4: Rozkład zmiennej 'Loudness'

W zbiorze danych mamy do czynienia z głośnymi utworami. Znaczna większość znalazła się w górnej części zakresu $<-20, 0>$.

- Speechiness - zakres $<0, 1>$




Rysunek 5: Rozkład zmiennej 'Speechiness'

Na podstawie wykresu i dokumentacji dołączonej do zbioru danych można stwierdzić, że większość utworów (poniżej wartości 0.33) jest bardziej mu-

zykalna. Mniejsza część, czyli z zakresu $\langle 0.33, 0.66 \rangle$, reprezentuje utwory, które zawierają i muzykę i elementy mówione, tak jak np. rap.


- Acousticness - zakres $\langle 0, 1 \rangle$



Rysunek 6: Rozkład zmiennej 'Acousticness'

Jeśli chodzi o akustyczność utworów, to są one dosyć równo rozłożone, z tendencją spadkową wraz ze wzrostem wskaźnika. Można stwierdzić, że bardzo duża część utworów nie jest zupełnie akustyczna.

- Instrumentalness - zakres $\langle 0, 1 \rangle$




Rysunek 7: Rozkład zmiennej 'Instrumentalness'

Bardzo mała ilość przekracza wartość wskaźnika instrumentalności 0.1,

oznacza to, że jest bardzo duże prawdopodobieństwo że trafimy w zbiorze na utwór zawierający słowa. Są jednak małe ilości, które nie dają aż tak dużej pewności oraz takie, które prawie na pewno nie zawierają słów.


- Liveness - zakres $<0,1>$



Rysunek 8: Rozkład zmiennej 'Liveness'

Można zauważyć, że duża część utworów była nagrywana w warunkach studyjnych, bez publiczności, co określa niski współczynnik zmiennej. Zawarte są jednak również utwory nagrywane na żywo przy obecności publiki, która jest słyszalna w ścieżce dźwiękowej.


- Valence - zakres $<0,1>$



Rysunek 9: Rozkład zmiennej 'Valence'

Jak widać na wykresie, mamy do czynienia z pełnym przekrojem utworów 'wesołych' i tych mniej 'wesołych', z mniejszą wartością dla wartości granicznych, która opisywałaby utwory przesadnie smutne i przesadnie wesołe. Ludzie często słuchają takich utworów jaki mają aktualnie nastrój, dlatego należy spodziewać się utworów z całego przekroju.


- Tempo - wartości całkowite <0 BPM, 244 BPM>



Rysunek 10: Rozkład zmiennej 'Tempo'

Jeśli chodzi o szybkość ścieżki, to najpopularniejszymi wyborami są te z zakresu od ok. 80 do 150 BPM. Artyści mogą wybierać takie podkłady, aby utwory nie były zbyt wolne lub zbyt szybkie dla słuchaczy. Ten zakres może być najbardziej przyswajany przez odbiorców. Wykres przejawia cechy rozkładu bimodalnego. Najpopularniejszymi wartościami wydają się wartości około 100 i 120 BMP.


- Duration [ms] - zakres <0 min, 10 min>



Rysunek 11: Rozkład zmiennej 'Duration_ms' przekonwertowanej na wartości w minutach

Najpopularniejszym wyborem długości utworu jest ten rokujący od 2.5 min do 4.5 min. Istnieją jednak utwory o długości sięgającej nawet 8 czy 10 minut.

- Views - zakres <0, ok. 8 mld>



Rysunek 12: Rozkład zmiennej 'Views'

Bardzo mała ilość utworów ze zbioru przekracza wartość odtworzeń wysokości nawet 10 mln. Znajdują się jednak nieliczne utwory, które sięgają nawet ok. 8 mld wyświetleń


- Stream - zakres <ok. 6,5 tys., ok. 3,4 mld>

Podobnie jak dla wyświetleń na YT, na Spotify znaczna ilość plasuje się w dolnych częściach zakresu. Wyświetlenia te są jednak nieco wyższe. może to być spowodowane, że niektórych niszowych utworów wstawionych na serwis YouTube nie znajdziemy na Spotify, na którym są wstawione bardziej profesjonalne dzieła. Wykres rozkładu zmiennej jak i gęstości jest bardzo podobny, więc nie zdecydowano się na zamieszczenie go w tym miejscu.

- Likes - zakres <0 , ok. 50 mln> Wykres rozkładu i gęstości zmiennej jest prawie identyczny do wykresu 'Views'. Te wartości są bardzo mocno skorelowane, utwory z dużymi ilościami polubień będą tymi najczęściej odtworzanymi. Choć mogą zdarzyć się przypadki, gdzie ta zależność będzie nieprawdziwa, bądź nawet odwrotna (np. piosenki znane z tego że mają najwięcej dislike'ów na YouTube).

• Gatunek

Na kolejnym wykresie pokazano ile utworów danego gatunku występuje w zbiorze danych (dla 15 najczęściej występujących). Warto zwrócić uwagę, że dla ponad 400 próbek nie udało się zdobyć informacji o ich gatunku. W ilości wystąpień przoduje pop, hip-hop, rap i rock, który również występuje w kilku podgatunkach.




Rysunek 13: Ilość wystąpień utworów danego gatunku w zbiorze danych.

2.6 Analiza zależności między zmiennymi

Na początku przedstawiono korelację pomiędzy zmiennymi. W kolejnych punktach przedstawiono zależność ilości wyświetleń od innych zmiennych, takich jak: gatunek, taneczność, tonacja, pozytywność. Pod koniec porównano ze sobą część najpopularniejszych gatunków pod względem zmiennych takich jak: taneczność, ilość słów, długość utworu oraz średnie tempo.

2.6.1 Korelacja poszczególnych zmiennych


Poniższy wykres przedstawia korelację poszczególnych zmiennych. Korelacja została wyznaczona metodą Pearsona. Widać że większość zmiennych nie jest ze sobą skorelowana, lecz jest od tego sporo wyjątków. Najbardziej widoczny jest blok korelacji znajdujący się w prawym dolnym rogu. Jest to ilość wyświetleń, ilość polubień, ilość streamów, i suma odtworzeń, które są skorelowane ze sobą nawzajem. Wynik taki jest przewidywalny, gdyż większość piosenek mająca dużą liczbę wyświetleń ma też dużą liczbę polubień. Kolejną wyróżniającą się korelacją jest ta występująca pomiędzy wartością głośności i energii. Można zauważyć również parę zmiennych, których korelacja jest odwrotnie proporcjonalna. Są to pary zmiennych takie jak: akustyczność i energia, akustyczność i głośność, instrumentalność i głośność. Jest wiele innych pomniejszych korelacji, można je przeanalizować przy pomocy załączonego obrazka.



Rysunek 14: Mapa ciepła korelacji poszczególnych zmiennych

2.6.2 Wyświetlenia od Gatunku

Na początek sprawdzona została zsumowana ilość wyświetleń każdego gatunku jaki występuje w badanym zestawie danych.




Rysunek 15: Wykres 10 najpopularniejszych gatunków według sumy odtworzeń na Spotify i YouTube

Z wykresu wynika, iż Pop wraz z Hip-Hopem uzbierały największą ilość wyświetleń po zebraniu tych zarówno z serwisu Youtube jak i Spotify. Ze względu na nierówną reprezentację wszystkich gatunków (gatunki nie mają równej liczby utworów w zbiorze) nie można jednoznacznie stwierdzić że muszą to być najpopularniejsze gatunki.

2.6.3 Wyświetlenia od Taneczności


Następnie zbadano zależność pomiędzy wyświetleniami a poziomem taneczności posiadającym wartości w zakresie od 0 do 1. Aby klarownie zobrazować tę zależność, wartości taneczności zostały podzielone na 20 zakresów. Dodatkowo z każdego zakresu taneczności wyciągnięto średnią ilość wyświetleń znajdujących się w nim utworów.



Rysunek 16: Wykres słupkowy średnich wyświetleń utworu o danym zakresie Taneczności

Wykres zależności sugeruje, że wraz ze wzrostem taneczności, rośnie liczba wyświetleń. Nie jest to jednak liniowa zależność i występują w niej wyjątki, chociażby wysoka liczba wyświetleń utworów o bardzo niskiej taneczności (poniżej 0,05). Być może jeden z gatunków cechuje się bardzo niską tanecznością, a mimo wszystko jest popularny, aczkolwiek bez dodatkowych analiz wniosek ten nie może być niczym poparty.


Dodatkowo, na poniższym wykresie punktowym można zauważyć inną perspektywę zależności. Widoczne są próbki oddalone od wygenerowanej linii trendu, co dodaje informację odnośnie wariancji danych. Jednocześnie wykres pokazuje, że mocno odbiegająca wartość w punkcie zerowym nie jest aż tak istotna jak wydawać by się mogło z powyższego histogramu.



Rysunek 17: Wykres punktowy średnich wyświetleń utworu o danej Taneczności

2.6.4 Wyświetlenia od Tonacji

Kolejną zależnością jest wpływ tonacji, w której utwór został napisany, na liczbę wyświetleń. Jak wynikało z analizy rozkładu zmiennych, nie każda tonacja jest wybierana z podobną częstotliwością dlatego też znowu badane są średnie wyświetlenia dla każdej z nich.




Rysunek 18: Wykres średnich wyświetleń utworów napisanych w danej tonacji

Histogram pokazuje iż utwory pisane w dowolnej tonacji mają szansę na podobną wysokość liczby wyświetleń. Wśród wszystkich utworów w zbiorze danych, najrzadziej wykorzystywana była tonacja D#/E. Jednak patrząc na wykres wywnioskować można, że najprawdopodobniej nie jest to decyzja wynikająca z małej popularności tejże tonacji.

2.6.5 Wyświetlenia od Pozytywności


Ostatnia analiza zależności odnośnie średniej wyświetleń odnosi się do poziomu pozytywności. Tutaj również wartości te zostały podzielone na 20 zakresów.



Rysunek 19: Wykres słupkowy średnich wyświetleń utworów o danym zakresie Pozytywności


Według uzyskanych wyników, w dość szerokim zakresie, od 0,1 do 0,95, średnia liczba wyświetleń jest bardzo zbliżona. Świadczyć to może o tym, że utwory cechujące się z grubsza każdym poziomem pozytywności lub jej niedoboru cieszą się podobnym zainteresowaniem. Prawdopodobnie jest to spowodowane faktem, że będąc pod wpływem różnych emocji sięgamy po inne gatunki muzyki i każde z nich znajdują swoją grupę odbiorców. Wyjątkiem są utwory o skrajnie niskiej pozytywności, a więc te mające wydźwięk negatywny, co może sugerować że utwory te nie są przyjemne do słuchania.

Ponownie po wyświetleniu wykresu przy pomocy punktów zauważyć można odbiegające liczby wyświetleń w kilku zakresach pozytywności. Szczególnie jest to widoczne dla mniejszych wartości, gdzie znajduje się również nadzwyczajnie duża liczba utworów. Warto zauważyć, że linia trendu jest kształtem bardzo zbliżona do histogramu.



Rysunek 20: Wykres punktowy średnich wyświetleń utworów o danym zakresie Pozytywności


2.6.6 Średnia taneczność w popularnych gatunkach



Rysunek 21: Wykres średniej taneczności w popularnych gatunkach

Z wykresu można wywnioskować że najbardziej tanecznym gatunkiem jest Reggaeton. Jest to dość interesujący wynik, gdyż można by przewidywać że muzyka pop będzie najbardziej tanecznym gatunkiem muzycznym, jednak Reggaeton ma bardzo silne nastawienie na taneczny rytm. Standardowe odchylenie jest dla wszystkich gatunków bardzo zbliżone.


2.6.7 Średnia ilość słów w popularnych gatunkach



Rysunek 22: Wykres średniej ilości słów w popularnych gatunkach

Zgodnie z przewidywaniami gatunek Hip-Hop ma średnio najwięcej słów w piosence w porównaniu z innymi piosenkami. Drugim gatunkiem jest Reggaeton który również zawiera bardzo dużo słów, gdyż zawiera dużo elementów Hip-Hopu. Niektóre z gatunków, takie jak Hip-Hop lub Reggaeton, mają duże odchylenie standardowe. Można wywnioskować że jest duża różnorodność ilości słów w tych gatunkach. Pozostałe gatunki nie mają aż takich dużych odchyleń.


2.6.8 Średnia długość utworu w popularnych gatunkach



Rysunek 23: Wykres średniej długości utworu w popularnych gatunkach

Można zauważyć że gatunkiem o najdłuższych utworach jest rock. Może być to związane z często najbardziej skomplikowanym układem kompozycyjnym utworu, co naturalnie prowadzi do zwiększenia długości piosenki. Z ciekawych obserwacji można zauważyć że średnio utwór z gatunku pop i rock trwają bardzo podobną ilość czasu, lecz ich odchylenie standardowe różni się znacząco. Wynika to z faktu że Hip-hop ma większą liczbę utworów dużo krótszych lub dłuższych od średniej, natomiast prawie wszystkie utwory z gatunku pop są zbliżonej długości.

2.6.9 Średnie tempo w popularnych gatunkach



Rysunek 24: Wykres średniego tempa w popularnych gatunkach


Można zauważyć że średnie tempa piosenek są bardzo zbliżone. Największe tempo ma muzyka Rock, która często cechuje się żywymi i dynamicznymi rytmemi. Jeden z gatunków z najniższym średnim tempem jest Reggaeton, który może być kojarzony z spokojniejszymi i bardziej relaksującymi rytmemi. Można zauważyć że większość gatunków ma bardzo podobne odchylenie standardowe.

3 Ekstrakcja wiedzy z danych

3.1 Wstęp

Techniki, które zostały wybrane do eksploracji danych, to: klastrowanie i predykcja. Wybrane zostały w celu przewidywania do jakiego gatunku należy piosenka na podstawie podanych parametrów.

W celu wizualizacji danych oraz wyników zastosowano metodę redukcji wymiarów PCA. W większości przypadków jako danych wejściowych użyto danych opisujących dany utwór, a jest ich aż 10, co wykracza poza możliwości wyobrażenia sobie danych w przestrzeni jak i również wyświetlenia ich w programie. Wymiary zostały zredukowane do dwóch, aby móc wyświetlić dane próbki na płaszczyźnie w celu łatwiejszej obserwacji i analizy.




Rysunek 25: Przykładowe próbki przedstawione na płaszczyźnie po operacji redukcji wymiarów.

3.2 Wyniki klastrowania

Łączenie gatunków w klastry odbyło się przy zastosowaniu różnych metod: metoda K-średnich, metoda DBSCAN oraz Birch.

Testowanie kolejnych metod klasteryzacji nie przynosiło dobrych rezultatów. Spowodowane jest to tym, że zbiory prawie że pokrywają się ze sobą, pomimo innego gatunku muzyki. Jakość klasteryzacji badano współczynnikiem ARI, który dla przedstawionego przypadku nie przekroczył 0.3. Tak wysoki wynik może być jednak spowodowany tym, że w przedstawionym przykładzie umieszczono znacznie odstający od reszty gatunek muzyki klasycznej, który jest stosunkowo prostszy do wyodrębnienia jego skupiska.



Rysunek 26: Wyniki klasteryzacji dla próbek podanych powyżej.


Warto zaznaczyć, że brak redukcji wymiarów nie pozwolił poprawić wyników grupowania oraz to, że dla metody K-means oraz birch jako parametr wejściowy podano docelową ilość klas do podziału.

```

1 Adjusted Rand Index KMEANS (z redukcja): 0.19869476369478445
2 Adjusted Rand Index KMEANS (bez redukcji): 0.18571873248045062
3 Adjusted Rand Index DBSCAN (z redukcja): 0.2631654986005983
4 Adjusted Rand Index DBSCAN (bez redukcji): -0.003069075247686727
5 Adjusted Rand Index BIRCH (z redukcja): 0.2894336338289306
6 Adjusted Rand Index BIRCH (bez redukcji): 0.2894336338289306

```

Brak możliwości jakościowej klasteryzacji dla najpopularniejszych 10 gatunków potwierdza ich wykres w przestrzeni dwuwymiarowej.



Rysunek 27: Wykres w przestrzeni 2D próbek z 10 najpopularniejszych gatunków.


3.3 Wyniki klasyfikacji

Klasyfikacja została przeprowadzona przy użyciu różnych metod, w celu znalezienia takiej która daje najlepsze wyniki. Klasyfikowane były piosenki z 10 najpopularniejszych gatunków. Klasyfikacja była przeprowadzana za pomocą parametrów: Danceability, Energy, Key, Loudness, Speechiness, Acousticness, Instrumentalness, Liveness, Valence, Tempo. Metody klasyfikacji które zostały wykorzystane oraz uzyskane wyniki dokładności predykcji na zbiorze testującym:

	MLP	KNN	Drzewo	Las losowy
Dokładność [%]	20%	33%	36%	41%

Dokładność wyników nie jest zbyt wysoka, lecz daje wyraźnie lepsze rezultaty niż losowe dopasowywanie gatunku, które w ogólności uzyskałoby dokładność równą 10%. Próby ulepszenia, w tym dostosowywanie parametrów, były podejmowane w celu uzyskania lepszych wyników, lecz powyższe wyniki wydają się być najlepsze dla tej klasyfikacji.

W celu lepszego zobrazowania i analizy klasyfikacji, ilość gatunków ograniczona została do trzech oraz pięciu. Tym razem, ze względu na najlepszą dokładność predykcji, został wykorzystany jedynie las losowy. Otrzymał on dla trzech oraz pięciu gatunków wyniki kolejno - 93,3% oraz 69,1%. Poniżej przedstawiona jest macierz pomyłek wygenerowana dla obu testów:



Rysunek 28: Macierze pomyłek dla klasyfikacji trzech oraz pięciu gatunków muzycznych

Można stwierdzić, że coraz więcej gatunków, pomimo swoich oryginalnej charakterystyki, zaczyna przedstawiać bardzo zbliżone cechy bądź mieszać je z cechami z innych gatunków tak, aby były możliwie przystępne dla słuchaczy. Dzieje się tak oczywiście nie we wszystkich utworach, ale można zauważyć, że bezpośrednia różnica pomiędzy gatunkami zaciera się coraz bardziej.

Dodatkowo w celu lepszej analizy dokładności, dodano wskaźnik oceny klasyfikacji F1, który uwzględnia nierówność liczby utworów w wybranych gatunkach:

	MLP	KNN	Drzewo	Las losowy
Dokładność - 3 gatunki [%]	48,11	88,14	89,43	93,29
F1 - 3 gatunki	0,36	0,88	0,89	0,93
Dokładność - 5 gatunków [%]	38,67	59,69	59,93	69,13
F1 - 5 gatunków	0,25	0,58	0,55	0,68

3.4 Zalety i wady zaproponowanych rozwiązań

3.4.1 Klastrowanie

Okazało się, że metoda redukcji wymiarów PCA nie wpłynęła negatywnie na wyniki. Nie można powiedzieć jednak o zaletach zaproponowanych rozwiązań do grupowania, jeśli skomplikowanie danych zawartych w bazie nie pozwoliło na osiągnięcie wyników, o których można by powiedzieć że są dobre i można na nich polegać. Wadą rozwiązań jest to, że nie pozwoliły na osiągnięcie wyników, mają małą ilość parametrów, którymi można operować w celu poprawy rezultatów. Za wadę można również uznać to, że dla algorytmów K-means i Birch należało podać docelową liczbę klastrów, jednak to pozwoliło zarazem otrzymać lepsze rezultaty.

3.4.2 Klasyfikacja

Biorąc pod uwagę perceptron wielowarstwowy i KNN można zauważyć różnicę w dokładności. W obu rozwiązaniach podjęte zostały próby dostosowania parametrów w celu uzyskania lepszych wyników. W związku z tym można wywnioskować, że w tym konkretnym przypadku lepsze jest użycie szybszego oraz prostszego w implementacji KNN.

Jeśli kładziemy nacisk na poprawność wyników klasyfikacji, niewielkim kosztem złożoności obliczeniowej, warto zastosować losowy las decyzyjny, który dla każdej ilości rozpatrywanych gatunków uzyskał najlepszą dokładność.

4 Kierunki dalszego rozwoju

W celu poprawy wyników zarówno zadania grupowania jak i klasyfikacji należałoby zastosować bardziej rozbudowane, głębokie modele sieci neuronowych. Po osiągnięciu zadowalających wyników można by zastosować rozwiązanie problemu w celu automatycznego przypisywania udostępnianych piosenek do odpowiadających im gatunków muzycznych na obydwu platformach. Dodatkowo modele mogły by zostać rozszerzone o naukę gatunku w którym najczęściej tworzy artysta, co dałoby dodatkowy punkt odniesienia dla odpowiedniej klasyfikacji w procesie decyzyjnym.

5 Podsumowanie

Podsumowując wyniki uzyskane z predykcji oraz klastrowania nie są zadowalające, ale pozwalają wyciągnąć wiele wniosków. Po pierwsze dane na których został opracowany nie umożliwiają prostego rozpoznawania gatunku piosenki na podstawie jej parametrów. Ponieważ zbiór danych miał nie mało danych, można wywnioskować że te parametry nie są wystarczające do wykonania tego zadania. Większość gatunków jest bardzo silnie przepleciona względem swoich parametrów. Możliwe że zadanie którego się podjęliśmy jest możliwe do wykonania, lecz trzeba do tego wykorzystać bardziej zaawansowane narzędzia.